Eksperymenty z k-NN

Dane

Zbiory danych wygenerowałem proceduralnie. Dla każdej klasy wykorzystałem dwa albo trzy `bloby` dobierając odchyelnie standardowe tak, aby dane wyraźnie na siebie nachodziły - przykładowo klasa `zielona` jest niejako przecięta klasą pomarańczową.

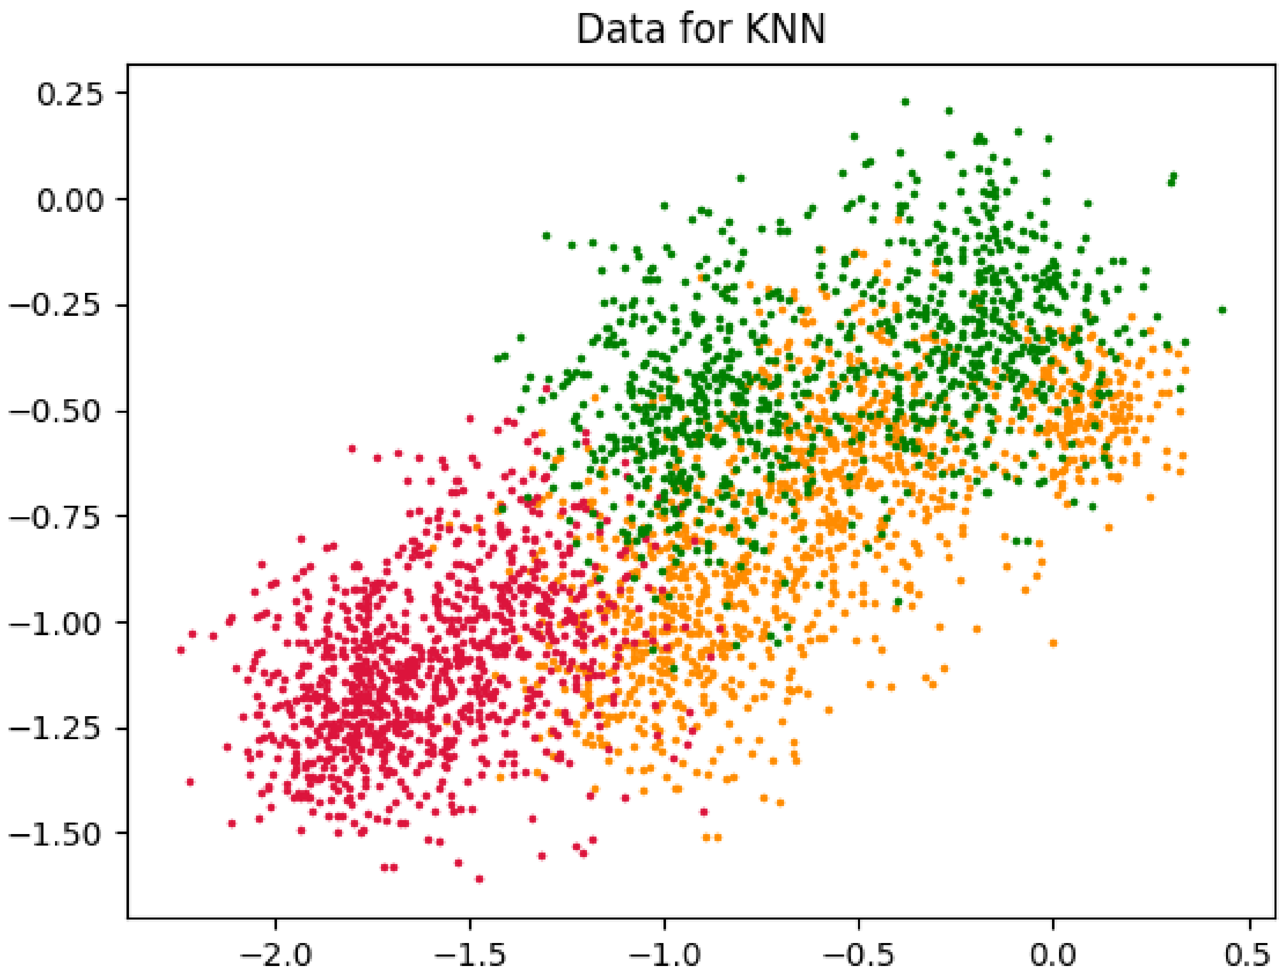

Egzemplarzy każdej klasy jest po 1000, za wyjątkiem klasy `pomarańczowej` których jest 1200.

Granica Decyzyjna

Badamy granicę decyzyjną dla poszczególnych hiperparamterów:

- k-NN z k=1, głosowaniem większościowym i metryką Euklidesa;
- k-NN z k=1, głosowaniem większościowym i metryką Mahalanobisa;
- k-NN z k=13, głosowaniem większościowym i metryką Euklidesa;
- k-NN z k=9, głosowaniem ważonym odległością i metryką Euklidesa.

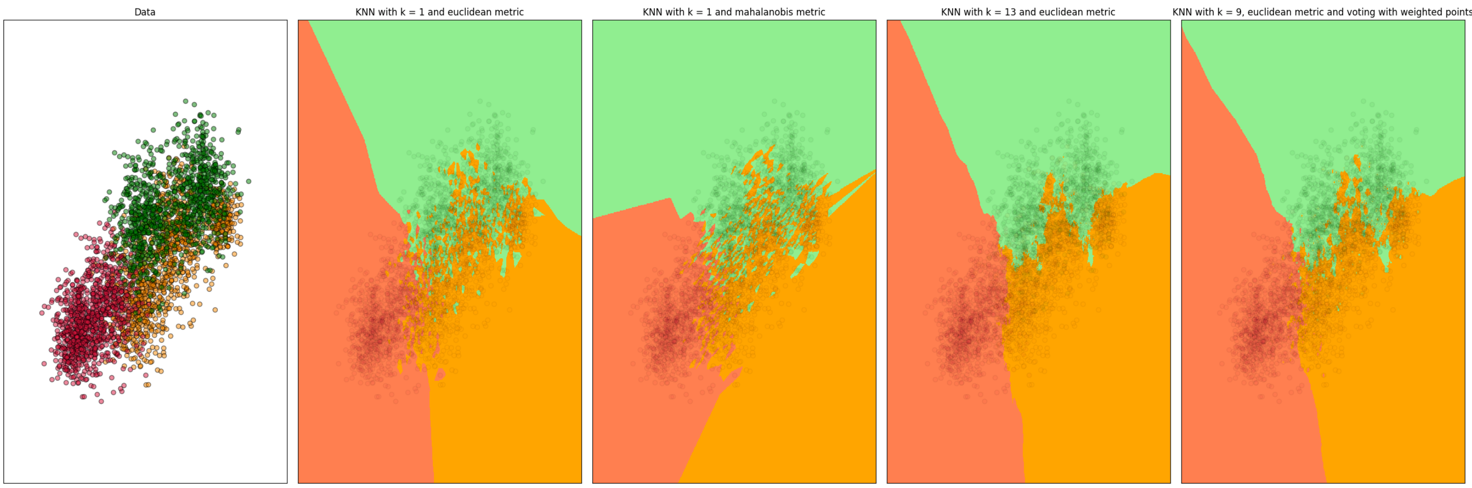

Dla k=1:

- dostajemy bardzo poszatkowaną przestrzeń - szczególnie dobrze wiadać w miejscu gdzie klasa pomarańczowa przecina dwie główne zgrupowania klasy zielonej.
- widzimy też różnicę w metrykach między euklidesową, a mahalanobisa:

$$d(x, y) = \sqrt{(x-y)^T S^{-1} (x-y)}$$

  , gdzie S to macierz kowariancji.
- bo rozłożenie naszych danych było nierównomierne i przekrzywione - macierz kowariancji:

```
[[0.36440023 0.16015485]
[0.16015485 0.13401288]]
```

Metryka Mahalanobisa bierze zatem pod uwagę rozłożenie naszych danych przez kowariancję.

Dla k = 9/13:

- tutaj widzimy, że zastosowanie dodawania wag do punktów proporcjonalnych od odwrotności ich odległości powoduje zachownie wysepek (czy chociaż ich cześci) innych klas wewnątrz większej.
- gdy po prostu braliśmy pod uwagę k-sąsiadów wysepki te były tracone z racji na fakt, że były one znaczącą mniejszością wewnątrz większego zbiorowiska innej klasy.
- innymi słowy ważenie punktów jest bardziej czułe na ich nietypowe rozłożenie.

Ocena sprawności klasyfikatora

Tu zdecydowałem się przetestować wszystkie powyższe konfiguracje. Procedurę z wyborem k dla poszczególnego klasyfikatora powtarzałem po 15 razy, a później całość (czyli wybór i ocena klasyfikatora) również po 15 razy.

Wybór k

Na początku należało wybrać k dla którego średnia skuteczność była najlepsza.

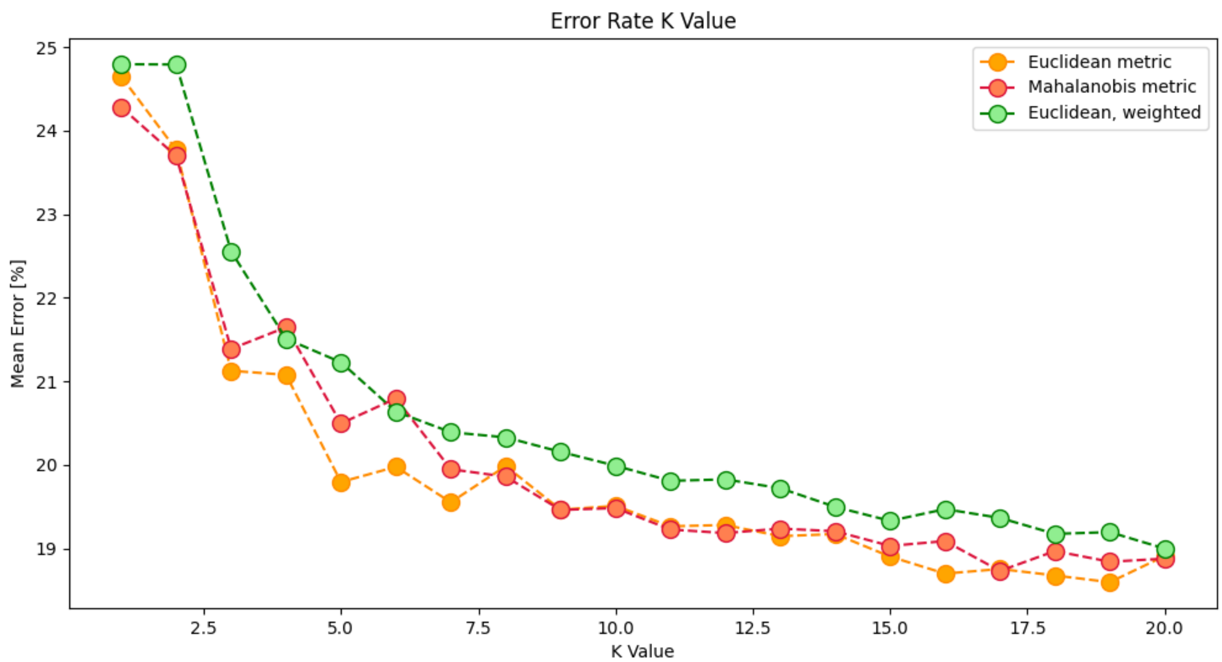

Figure 1: img

Na wykresie są uśrednione błedy z ($15 \cdot 15 = 225$) powtórzeń dla próbowanych k. Błędy są liczone na losowym zbiorze walidacyjnym (tak jak w treści).

Widać, że dla takiego rozłożenia danych większe k średnio wypadało lepiej dla każdego klasyfikatora.

Średnia skuteczność

Następnie sprawdzamy średnią skuteczność klasyfikatorów z najlepszym dla niego k.

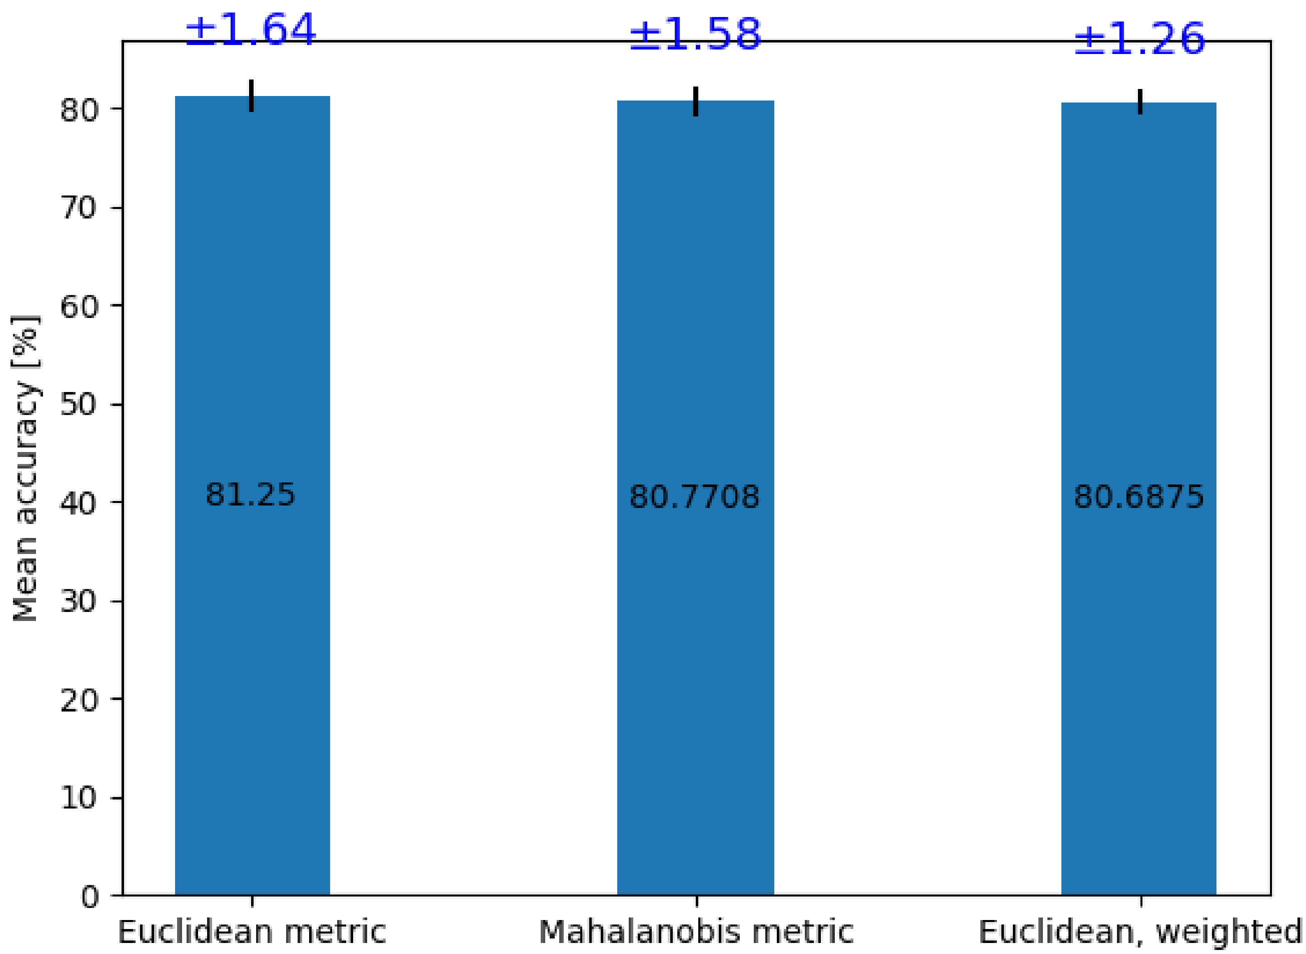

Okazuje się, że wszystkie te klasyfikatory radzą sobie niemalże tak samo dobrze. A im wyższa dokładność tym większe odchylenie standardowe.