

# Główne składowe butów

## Dane

Jako dane wybrałem zdjęcia ze sklepu Kazar (nie, nie jest to zbiór Zalando MNIST :) ), po 8 par sneakersów, oxfordów i mokasynów. Wszystkie zdjęcia były robione z tego samego ujęcia i po przycięciu (aby wycentrować) mają wymiary 400x280.




Takie zdjęcia sprowadzałem do wymiarów 100 na 100 i skali szarości, a całość trzymałem w macierzy z  $(100 \times 100 = 10000, 24)$  - każda kolumna to zdjęcie.

## Dataset



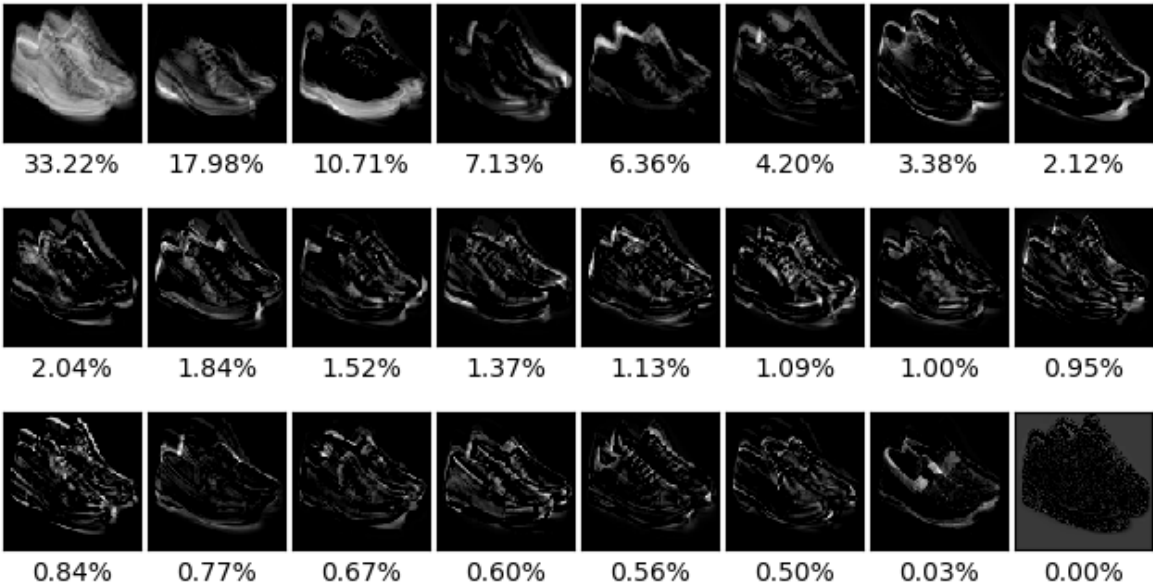
## Średnie zdjęcie


Najwyraźniej widać w nim rysy oxfordów i sneakersów. Jako że buty na zdjęciach były wycentrowane, nie widzimy zbyt dużego rozmazania oprócz tego, które bierze się z faktu, że były to zdjęcia różnych butów.



Wektory bazowe - Principal Components

Principal Components in Feature Space



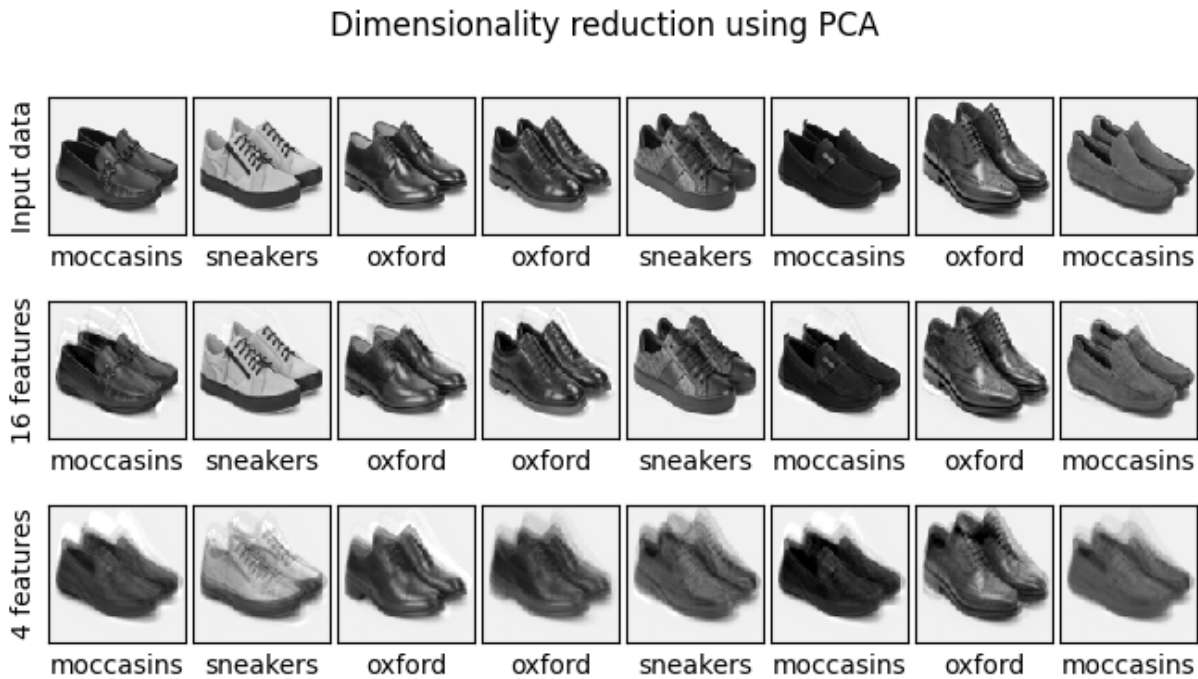


Wariancja w zależności od ilości wybranych wektorów bazowych (principal components).

Możemy zauważyć, że większość wariancji jest opisywana przez zaledwie kilka wektorów bazowych (przy dziesięciu mamy 90%) co sugeruje, że pozbycie się tych, które wnoszą najmniej, nie powinno nas kosztować dużo dokładności.

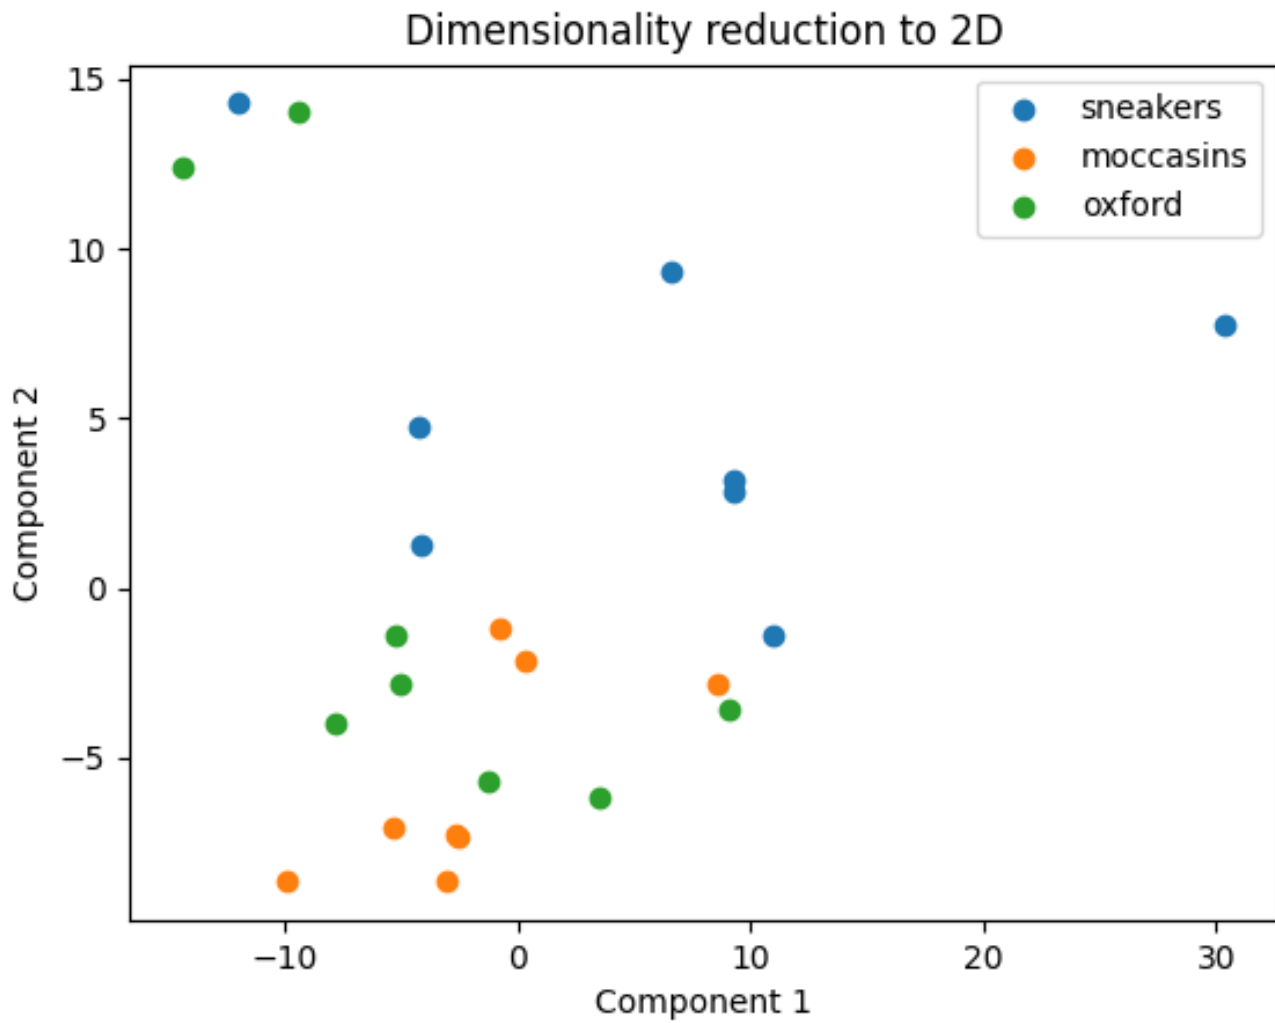
# Redukcja wymiarowości

Redukujemy wymiarowość naszych obserwacji do szesnastu i czterech najważniejszych cech.



Pokazałem tu tylko 8 zdjęć i sprawdziłem, jak wyglądają po redukcji wymiarów i przed (wertykalnie). Przy szesnastu nie widać dużej straty jakości, natomiast przy czterech zdjęcia są wyraźnie rozmyte - natomiast dalej dobrze widać ich rysy.

## Redukcja wymiarowości do 2D



Z wyjątkiem klasy zielonej, która niejako przecina klasę pomarańczową i kilku outlierów, klasy są odseparowane od siebie. k-NN całkiem przyzwoicie radzi sobie z wysepkami jednych klas w innych natomiast ciężko powiedzieć jak rozłożyłaby się większa ilość danych - już przy tych 24ech egzemplarzach mamy stosunkowo duży ich rozrzut i ciężko stwierdzić czy nie przesadziliśmy z redukcją wymiarów (co skądinąd i tak bardzo dobrze wygląda, jak na tylko dwa wymiary!)